


凸集

如果一个集合 C 中的任意两点之间的线段也在该集合中，即集合 C 满足以下条件：

$$\forall x_1, x_2 \in C, \theta \in \mathbb{R}, 0 \leq \theta \leq 1 \\ \theta x_1 + (1 - \theta)x_2 \in C$$

那么集合 C 可以称为凸集.



推广至一般情况，对于参数 θ 的不同约束可得到


名称	约束
凸集	$\sum_i^n \theta_i = 1, \theta_i \geq 0$
仿射集	$\sum_i^n \theta_i = 1$
凸锥	$\forall \theta_i \geq 0$

凸函数

如果函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足以下条件：

$$\forall x_1, x_2 \in \text{dom}(f), \theta \in \mathbb{R}, 0 \leq \theta \leq 1 \\ f(\theta x_1 + (1 - \theta)x_2) \leq \theta f(x_1) + (1 - \theta)f(x_2)$$

其中， $\text{dom}(f)$ 是凸集，那么函数 f 是一个凸函数.



严格凸 | 当 $x_1 \neq x_2, 0 < \theta < 1$.

凹函数 | 当 $-f$ 是一个凸函数.


严格凹 | 当 $-f$ 是一个严格凸函数.

推广至多个数据点， $\sum_i^n \theta_i = 1, \theta_i \geq 0$

$$f(\sum_{i=1}^n \theta_i x_i) \leq \sum_{i=1}^n \theta_i f(x_i).$$

即 $f(\mathbb{E}[x]) \leq \mathbb{E}[f(x)]$ ，称为**Jensen不等式**.

凸函数的几何意义




判断函数凸性的方式 ✓ 一阶条件 ✓ 二阶条件

一阶条件 | 如果一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $\text{dom}(f)$ 上处处可导，满足以下条件：

$$\forall x_1, x_2 \in \text{dom}(f) \\ f(x_2) \geq f(x_1) + \nabla f(x_1)^T (x_2 - x_1)$$

则 f 为凸函数



二阶条件 | 如果一个函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $\text{dom}(f)$ 上的所有点二阶导数存在，并满足以下条件：

$$\forall x \in \text{dom}(f) \quad \nabla^2 f(x) \succeq 0$$

即如果 f 的Hessian矩阵为半正定矩阵，那么 f 为凸函数.

常见凸优化问题的数学描述

线性规划	二次规划	二次约束二次规划	半定规划
$G \in \mathbb{R}^{m \times n}, A \in \mathbb{R}^{p \times n}$	$G \in \mathbb{R}^{m \times n} A \in \mathbb{R}^{p \times n}, P \in \mathbb{R}_+^n$	$P_i \in \mathbb{S}_+^n, i = 1, \dots, m$	$C, A_1, \dots, A_p \in \mathbb{S}^n$
$\min_x c^T x + d$ s.t. $Gx \preceq h$ $Ax = b$	$\min_x \frac{1}{2} x^T P x + q^T x + r$ s.t. $Gx \preceq h$ $Ax = b$	$\min_x \frac{1}{2} x^T P_0 x + q_0^T x + r_0$ s.t. $Ax = b$ $\frac{1}{2} x^T P_i x + q_i^T x + r_i \leq 0$	$\min_x \text{Tr}(CX)$ s.t. $\text{Tr}(A_i X) = b_i$ $X \succeq 0$

优化问题

标准形式 | 给定 $x \in \mathbb{R}^n$ ，在满足条件 $f_i(x) \leq 0$ 以及 $h_i(x) = 0$ 的所有 x 中寻找极小化 $f_0(x)$ 的取值，即

$$\min_x f_0(x) \quad | \quad \text{目标函数} \mathbb{R}^n \rightarrow \mathbb{R} \\ \text{s.t. } f_i(x) \leq 0, i = 1, \dots, m \quad | \quad \text{不等式约束} \mathbb{R}^n \rightarrow \mathbb{R} \\ h_i(x) = 0, i = 1, \dots, p \quad | \quad \text{等式约束} \mathbb{R}^n \rightarrow \mathbb{R}$$

当 $m = p = 0$ ，该问题称为**无约束问题**

如果问题定义域中的 x 满足约束条件，那么 x 是可行的；所有可行点的集合称为**可行集**

最优值 | 满足以下条件的 $p^* \in [-\infty, \infty]$:

$$p^* = \inf\{f_0(x) | f_i(x) \leq 0, h_i(x) = 0\}$$

✓ 如果问题不可行，则 $p^* = \infty$

✓ 如果 x_k 为可行解，满足 $k \rightarrow 0, f_0(x + k) \rightarrow -\infty$

则 $p^* = -\infty$ ，该优化问题**无下界**

最优点 | 最优点 x^* 是可行解，且 $f_0(x^*) = p^*$

局部最优 | 可行解 x 为局部最优解，如果存在 $R > 0$ ，使得以下条件成立

$$f_0(x) = \inf\{f_0(y) | f_i(y) \leq 0, i = 1, \dots, m, \\ h_i(y) = 0, i = 1, \dots, p, \|y - x\|_2 \leq R\}$$

松弛变量 | 引入 $s \in \mathbb{R}^m$ ，将不等式约束替换为等式约束，原优化问题可以表示为

$$\min_x f_0(x) \\ \text{s.t. } s_i \geq 0, i = 1, \dots, m \\ f_i(x) + s_i = 0, i = 1, \dots, m \\ h_i(x) = 0, i = 1, \dots, p$$

凸优化问题

凸优化问题 | 形如以下格式的优化问题

$$\min_x f_0(x) \\ \text{s.t. } f_i(x) \leq 0, i = 1, \dots, m \\ a_i^T x = b_i, i = 1, \dots, p$$

其中， f_0, \dots, f_m 均为凸函数

凸优化问题的特点 | 满足以下条件：

✓ 目标函数必须是凸函数

✓ 不等式约束函数必须是凸函数

✓ 等式约束约束函数必须是仿射函数

✓ **局部最优解**和**全局最优解**等价

如果目标函数**可微**，根据凸函数的定义，有

$$\forall x, y \in \text{dom}(f) \\ f(y) \geq f(x) + \nabla f(x)^T (y - x)$$


凸优化问题的**可行集** X 可表示为

$$X = \{x | f_i(x) \leq 0, h_i = 0\}$$

最优解 | x 为最优解，当且仅当满下条件

$$\begin{cases} x \in X \\ f(y) \geq f(x) + \nabla f(x)^T (y - x) \end{cases}$$

$f_0(x)$ **最优性条件**的几何意义



常见的凸优化问题形式：

线性规划 | 仿射目标函数和约束函数.

二次规划 | 二次型目标函数和仿射约束函数.

二次约束二次规划 | 二次型目标、约束函数.

半定规划 | n 维对称矩阵.

对偶

Lagrange函数 | 获取优化问题约束条件的加权和，放入原有目标函数，得到增广的目标函数

$$\mathcal{L}:\mathbb{R}^n\times\mathbb{R}^m\times\mathbb{R}^p\rightarrow\mathbb{R}$$

$$\mathcal{L}(x,\lambda,v)=f_0(x)+\sum_{i=1}^m\lambda_if_i(x)+\sum_{i=1}^pv_ih_i(x)$$


其中， λ_i,v_i 为对应的Lagrange乘子

Lagrange对偶函数 | 对于 $\lambda\in\mathbb{R}^m,v\in\mathbb{R}^p$ ，Lagrange函数有关 x 可以取得的最小值

$$g:\mathbb{R}^m\times\mathbb{R}^p\rightarrow\mathbb{R}$$

$$g(\lambda,v)=\inf_x\left(f_0(x)+\sum_{i=1}^m\lambda_if_i(x)+\sum_{i=1}^pv_ih_i(x)\right)$$

最优值下界 | Lagrange对偶函数为原始优化问题最优值 p^* 的下界，即 $\forall\lambda\geq 0,\lambda,g(\lambda,v)\leq p^*$



共轭函数 | 给定函数 $f:\mathbb{R}^n\rightarrow\mathbb{R}$ ，共轭函数 f^* 为

$$f^*(y)=\sup\left(y^Tx-f(x)\right)$$

Lagrange函数和共轭函数的联系 | 给定具有等式约束的优化问题 $\min_x f(x)$ s.t. $x=0$

✓该问题的Lagrange函数为 $\mathcal{L}=f(x)+v^Tx$

✓Lagrange函数的对偶函数为

$$\begin{aligned} g(v) &= \inf_x \left(f(x) + v^T x \right) \\ &= -\sup_x \left(-f(x) + (-v)^T \right) = -f^*(-v) \end{aligned}$$

Lagrange对偶问题 | 原问题最优值 p^* 的下界，与 λ,v 相关，可以描述为一个新的优化问题

$$\max_{\lambda,v} g(\lambda,v) \quad \text{s.t. } \lambda\geq 0$$

由于目标函数为凹函数，约束集合为凸集，对偶问题仍是凸优化问题；对偶问题的凸性和原问题无关；如果 (λ^*,v^*) 为对偶问题的最优解，那么 (λ^*,v^*) 称为**最优Lagrange乘子**。

弱对偶性 | 如果 d^* 表示Lagrange对偶问题的最优取值，那么不等式 $d^*\leq q^*$ ；即使原问题不是凸优化问题，该不等式依然成立。

最优对偶间隙 | p^*-d^*

如果原问题很难求解，那么基于弱对偶性，可以将求解原问题转化为求解其对偶问题

强对偶性 | 等式 $d^*=p^*$ 成立，即最优对偶间隙为零；一般情况下，强对偶性不成立；如果原问题是一个凸问题，强对偶性通常成立

Lagrange对偶的鞍点解释

对偶性的极大极小描述 | 假设优化问题没有等式约束，可以有

$$\begin{aligned} \sup_{\lambda\geq 0}\mathcal{L}(\lambda,x) &= \sup_{\lambda\geq 0}\left(f_0(x)+\sum_{i=1}^m\lambda_if_i(x)\right) \\ &= \begin{cases} f_0(x) & f_i(x)\leq 0,i=1,\cdots,m \\ \infty & \text{其他} \end{cases} \end{aligned}$$

基于上式，原问题的最优值可以表示为

$$p^*=\inf_x\sup_{\lambda\geq 0}\mathcal{L}(x,\lambda)$$

同样地，对偶问题则可以表示为

$$d^*=\sup_{\lambda\geq 0}\inf_x\mathcal{L}(x,\lambda)$$

弱对偶性可以使用下列不等式表示

$$\sup_{\lambda\geq 0}\inf_x\mathcal{L}(x,\lambda)\leq\inf_x\sup_{\lambda\geq 0}\mathcal{L}(x,\lambda)$$

强对偶性可以使用下列等式表示

$$\sup_{\lambda\geq 0}\inf_x\mathcal{L}(x,\lambda)=\inf_x\sup_{\lambda\geq 0}\mathcal{L}(x,\lambda)$$

极大极小不等式 | $\forall f:\mathbb{R}^n\times\mathbb{R}^m\rightarrow R$ ，以下不等式成立，且 $W\subseteq\mathbb{R}^n,Z\subseteq\mathbb{R}^m$

$$\sup_{z\in Z}\inf_{w\in W}f(w,z)\leq\inf_{w\in W}\sup_{z\in Z}f(w,z)$$

如果等式成立， f 则满足**鞍点**性质

鞍点 | $\forall w\in W,z\in Z$ ，下列不等式成立

$$f(\tilde{w},z)\leq f(\tilde{w},\tilde{z})\leq f(w,\tilde{z})$$

(\tilde{w},\tilde{z}) 称为函数 f 的鞍点；如果 x^* 为原问题的最优点， λ^* 为对偶问题的最优点，且强对偶性成立，那么 (x^*,λ^*) 为Lagrange函数的鞍点。

最优性条件

互补松弛性 | 若优化问题的强对偶性成立，给定 $x^*、(\lambda^*,v^*)$ 为原问题和对偶问题的最优解，有

$$\begin{aligned} f_0(x^*) &= g(\lambda^*,v^*) \\ &= \inf_x\left(f_0(x)+\sum_{i=1}^m\lambda_i^*f_i(x)+\sum_{i=1}^pv_i^*h_i(x)\right) \\ &= f_0(x^*)+\sum_{i=1}^m\lambda_i^*f_i(x^*)+\sum_{i=1}^pv_i^*h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

从上式可以得知 $\sum_{i=1}^m\lambda_i^*f_i(x^*)=0$ ，即 $\lambda_i^*f_i(x^*)=0$ 互补松弛条件可以表示为

$$\begin{cases} \lambda^*>0\implies f_i(x^*)=0 & \text{或者} \\ \lambda^*<0\implies f_i(x^*)=0 \end{cases}$$

KKT条件 | 若优化问题的目标函数和约束函数可微，对偶间隙为零。那么， $\mathcal{L}(x,\lambda^*,v^*)$ 在 $x=x^*$ 处取得最小值，则有

$$\nabla f_0(x^*)+\sum_{i=1}^m\lambda_i^*\nabla f_i(x^*)+\sum_{i=1}^pv_i^*\nabla h_i(x^*)=0$$

因此，列出优化问题的**KKT条件**

$$\begin{cases} f_i(x)\leq 0,i=1,\cdots,m \\ h_i(x^*)=0,i=1,\cdots,p \\ \lambda_i^*\geq 0,i=1,\cdots,m \\ \lambda_i^*f_i(x^*)=0,i=1,\cdots,m \\ \nabla f_0(x^*)+\sum_{i=1}^m\lambda_i^*\nabla f_i(x^*)+\sum_{i=1}^pv_i^*\nabla h_i(x^*)=0 \end{cases}$$

凸问题的KKT条件 | 如果原问题为凸问题，满足KKT条件的点也是原问题和对偶问题的最优解。

Slater条件 | $\exists\in\text{relint}\mathcal{D}$ ，使得下式成立

$$f_i(x)<0,i=1,\cdots,m \quad Ax=b$$

其中 \mathcal{D} 为目标函数定义域， $\text{relint}\mathcal{D}$ 为定义域的相对内部。当Slater条件成立且原问题为凸问题时，强对偶性成立

- ✓如果凸优化问题的目标函数和约束函数可微，且满足Slater条件，那么KKT条件为该问题最优性的**充要条件**
- ✓在实际的情形下，求解凸问题的方法可以转换为求解其KKT条件的方法。

凸优化算法概要

无约束优化 | 优化问题的目标函数 $f:\mathbb{R}^n\rightarrow\mathbb{R}$ 二次可微，最优点满足充要条件

$$\nabla f(x^*=0)$$

通过计算上述方程的解，得到优化问题的最优解；实际情形中，使用**迭代算法**获得最优解，计算数列 x^0,x^1,\cdots,x^k ，使得 $k\rightarrow\infty$ ， $f(x^k)\rightarrow p^*$

下降方法 | 该方法产生一个数列 $\{x^k\}k=1,\cdots$ ，满足以下的等式

$$x^{k+1}=x^k+t^k\Delta x^k$$

其中， Δx 表示**搜索方向**； t^k 表示第 k 次迭代的**步长**；下降方法的搜索方向必须满足

$$\nabla f(x^k)^T\Delta x^k<0$$

下降方法算法框架 | 重复以下步骤，直至满足终止条件

- ✓确定搜索方向 Δx
- ✓使用合适的搜索方法确定步长 $t>0$
- ✓更新 x ， $x:=x+t\Delta x$

梯度下降法 | 负梯度为搜索方向 $\Delta x=-\nabla f(x)$

Newton法 | Newton法的搜索方向：

$$\Delta x_{Newton}=-\nabla^2f(x)^{-1}\nabla f(x)$$

等式约束优化 | 优化问题的目标函数 $f:\mathbb{R}^n\rightarrow\mathbb{R}$ 为二次连续可微凸函数，最优点满足充要条件

$$Ax^*=b,A\in\mathbb{R}^{p\times n},\nabla f(x^*)+A^Tv^*=0$$

等式约束优化问题可以通过以下两种方式求解：

- ✓消除等式约束转化为等价的无约束优化问题
 - ✓求解对偶问题，从对偶解中复原原问题最优解
- Newton法** | 假设KTT矩阵非奇异，确定Newton方向

$$\begin{bmatrix} \nabla^2f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{newton} \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

其中， w 为优化问题的最优对偶变量

内点法 | 使用内点法求解不等式约束问题，实质是使用Newtorn法求解一系列等式约束问题

障碍法 | 顺序求解一系列等式约束或者无约束优化问题，每次使用获取的最新点作为求解下一个优化问题的起始点，该方法称为序列无壁垒输极小化技术，也称为**障碍方法**，或者**路径跟踪法**。