

基本概念

独立 | 给定变量 x, y ，若其联合概率分布 $p(x, y)$ 可以写为 $p(x, y) = p(x)p(y)$. 那么，变量 x 和变量 y 独立.

条件独立 | 给定变量 x, y, z ，若其条件分布 $p(x, y|z)$ 可以写为

$$p(x, y|z) = p(x|z)p(y|z).$$

那么，变量 x 和 y 在 z 的条件下独立，记为 $x \perp\!\!\!\perp y|z$.


似然函数 | 给定模型参数 θ ，观测数据 \mathcal{D} ，模型的似然函数为

$$p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}|\theta)p(\theta)}{p(\mathcal{D})} = \frac{p(\mathcal{D}|\theta)p(\theta)}{\int_{\theta} p(\mathcal{D}|\theta)p(\theta)d\theta}$$

其中 $p(\mathcal{D}|\theta)p(\theta)$ 为后验概率分布， $p(\theta)$ 为先验概率分布. 如果先验概率分布为常数，那么**最大后验估计**(MAP)等价于**最大似然估计**(MLE).

无向图 | 无向边和节点组成的图.

有向图 | 有向边和节点组成的图.



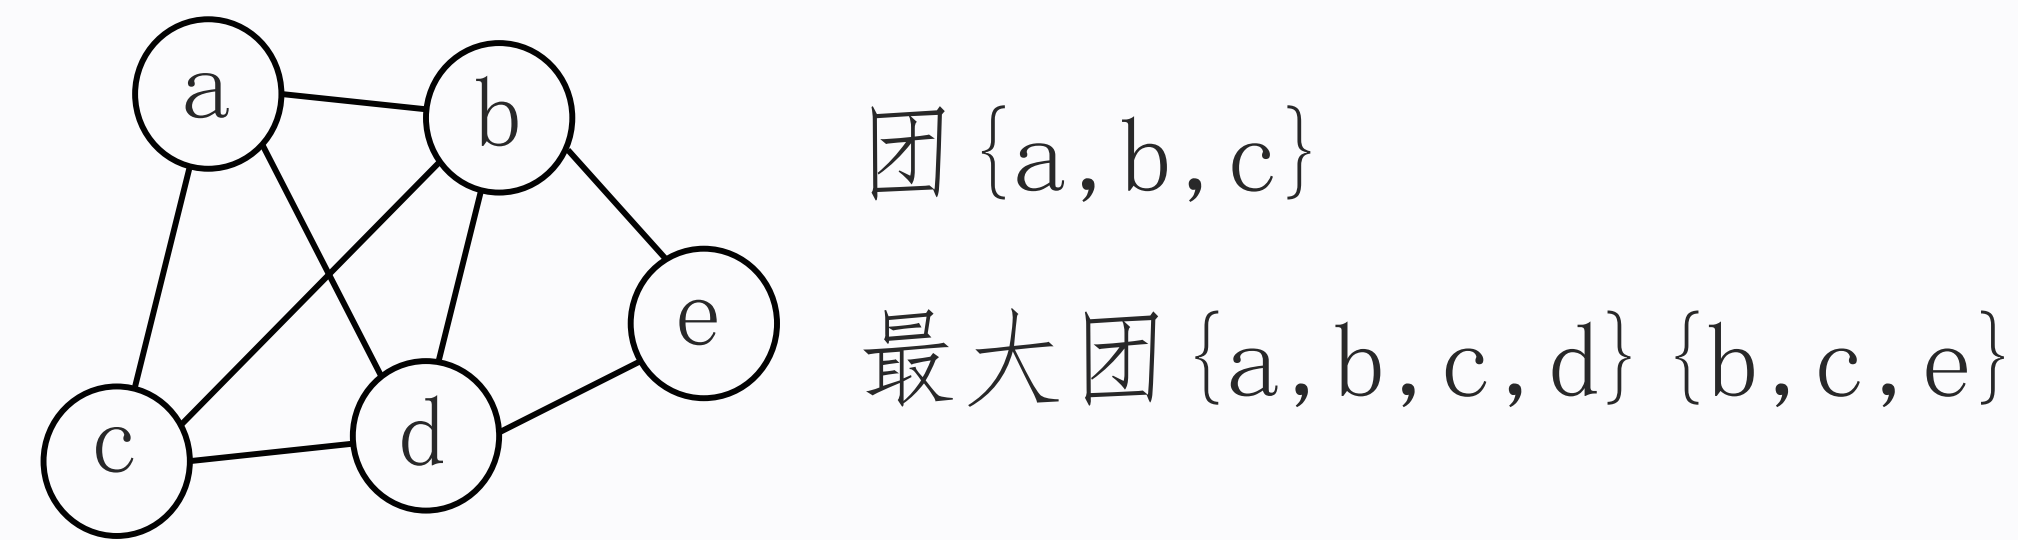
有向图

无向图

有向无环图 | 任意一条边有方向，且没有环的图.

团 | 无向图中两两连接的顶点的子集.

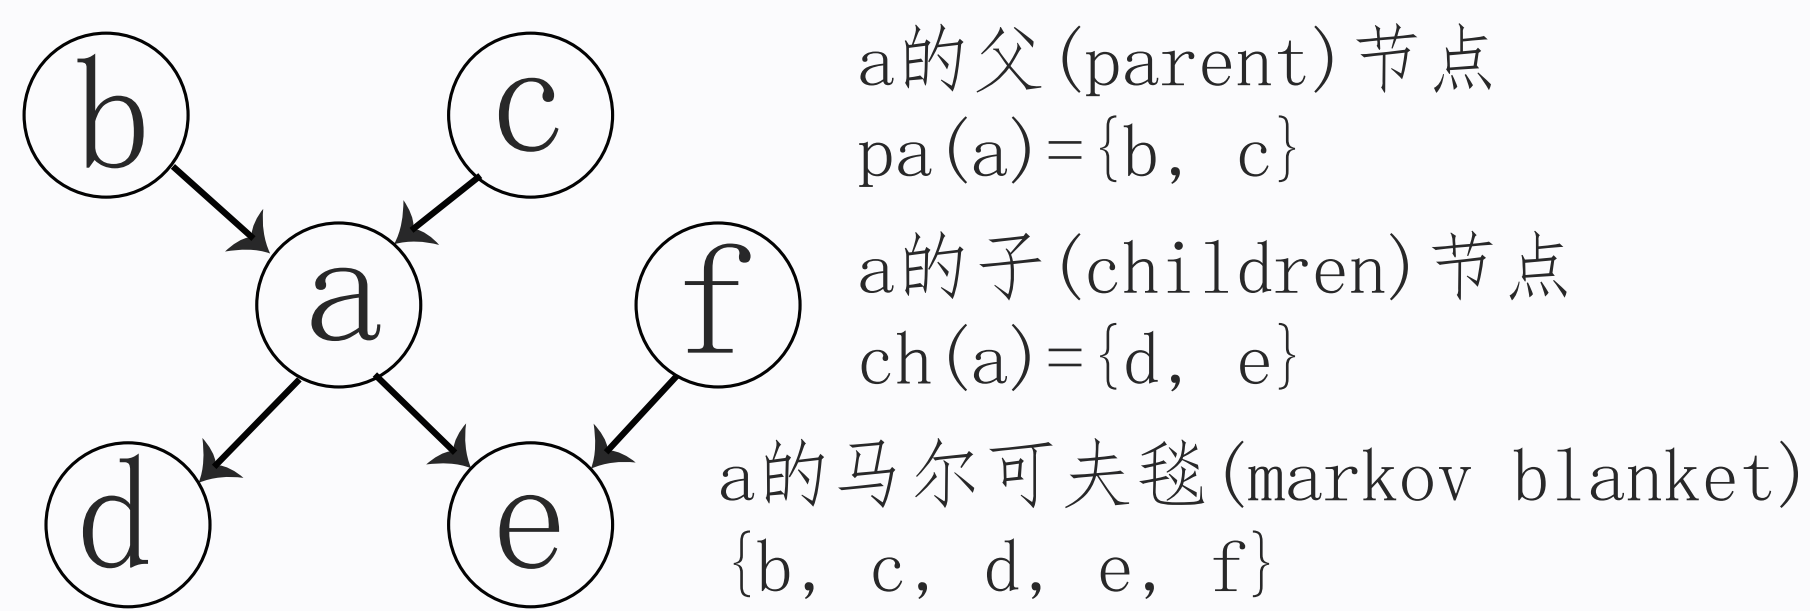
极大团 | 一个团，且不存在点与团顶点之间有边.



团 {a, b, c}

最大团 {a, b, c, d} {b, c, e}

无向图中的关系 | 以下图的节点 a 为例



a的父(parent)节点
pa(a)={b, c}

a的子(children)节点
ch(a)={d, e}

a的马尔可夫毯(markov blanket)
{b, c, d, e, f}


有向图模型

信念网络 | 指的是形如下式的概率分布

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | \text{pa}(x_i))$$

信任网络可以表示为一个有向图，图中的有向边从父节点指向子节点，图中的节点表示因子 $p(x_i | \text{pa}(x_i))$. 根据贝叶斯法则，概率分布写为

$$\begin{aligned} p(x_1, \dots, x_n) &= p(x_1 | x_2, \dots, x_n) p(x_2, \dots, x_n) \\ &= p(x_1 | x_2, \dots, x_n) p(x_2 | x_3, \dots, x_n) p(x_3, \dots, x_n) \\ &= p(x_n) \prod_{i=1}^{n-1} p(x_i | x_{i+1}, \dots, x_n) \end{aligned}$$



根据上图， $p(x_1, x_2, x_3, x_4)$ 为


$$p(x_1 | x_2, x_3, x_4) p(x_2 | x_3, x_4) p(x_3 | x_4) p(x_4)$$

阻塞 | 给定 B, C, D 为有向图中任意不相交的节点集. 若 D 为条件集合（ D 的节点被观测到），从 B 中节点到 C 中节点的所有可能路径中，某条路径被堵塞，如果该路径包含节点 n 满足以下任一条件：

✓在节点 n 处，路径上的有向边呈现“头对尾”或者“尾对尾”的形态，且 $n \in D$;

✓在节点 n 处，有向边呈现“投对头”的形态，且 $n, \text{ch}(n) \notin D$.

有向分离 | 如果从 B 到 C 的所有路径都被堵塞，那么 B 和 C 被 D 有向分离. 因此，有向图所表示的有关这些节点的联合概率分布满足 $B \perp\!\!\!\perp C | D$.



在上图中，从 a 到 b 的路径没有被 c 阻塞.

因为在 c 处，有向边呈“头对头”的形态，但是节点 c 在条件节点集合中，即 c 被观测到，用阴影表示.

无向图模型

势函数 | 变量 x 的一个非负函数，即 $\phi(x) \geq 0$.

变量的分布是一个特例，视为一个归一化的势函数， $\sum_x \phi(x) = 1$. 分布 $p(a, b, c)$ 还可以分解为

$$p(a, b, c) = \frac{1}{Z} \phi(a, b) \phi(b, c), Z = \sum_{a, b, c} \phi(a, b) \phi(b, c)$$


马尔可夫网络 | 给定 $\mathcal{X} = \{x_1, \dots, x_n\}$ ，马尔可夫网络是变量集合 $X_c \in \mathcal{X}$ 定义的势函数的乘积.

$$p(x_1, \dots, x_n) = \frac{1}{Z} \prod_{c=1}^C \phi_c(X_c)$$

其中 X_c 为网络对应的无向图中的极大团.

分离 | 给定无向图 G 中三个不相交的节点子集 B, C, D ，如果从 B 中节点到 C 中节点的每一条路径都需要通过 D ，那么 B 和 C 被 D 分离.

全局马尔可夫性 | 给定无向图的三个不相交的节点子集 B, C, D ，且子集 D 将子集 B 和子集 C 分离，则有 $B \perp\!\!\!\perp C | D$.



马尔可夫网络

链式图


由上图的马尔可夫网络可知 $x_1 \perp\!\!\!\perp x_7 | \{x_3, x_4, x_5\}$.

链式图模型 | 同时包含有向边和无向边的图模型.

链式成分 | 链式图去掉有向边，剩余的相互连接的部分. 上图的链式成分有 $(a), (b), (c, d)$.

因子图模型 | 给定 $p(x_1, \dots, x_n) = \prod_i \psi_i(X_i)$ ，因子图模型中的方块对应函数中的因子 ψ_i ，节点表示变量 x_j ，对于 $x_j \in X_i$ ，存在一条无向边连接 ψ_i 和 x_j .

例如， $p(a, b, c) = \phi(a, b) \phi(b, c) \phi(a, c)$.



马尔可夫网络

因子图

independence map | 给定概率分布 P 以及对应的图 G ，如果从 G 中推断出的条件独立在分布 P 中真实存在，那么 G 为分布 P 的I-map.

dependence map | 给定概率分布 P 以及对应的图 G ，如果分布 P 中表示的条件独立在 G 中真实存在，那么 G 为分布 P 的D-map.

图模型的推断


边缘推断 | 若 $p(x_1, \dots, x_4), x_1 = b$ ，边缘推断可为

$$p(x_4 | x_1 = b) \propto \sum_{x_2, x_3} p(x_1 = b, x_2, x_3, x_4)$$

变量消除 | 逐次消除分布的变量，计算边缘分布.

$$p(a) = \sum_{b, c, d} p(a, b, c, d) = \sum_{b, c, d} p(a|b) p(b|c) p(c|d) p(d)$$

$$= \sum_b p(a|b) \overbrace{\sum_c p(b|c) \sum_d p(c|d) p(d)}^{\gamma_d(c)}$$



马尔可夫链

因子图

sum-product算法 | 在因子图上计算边缘分布.

$$p(a, b, c) = \sum_{b, c, d} \phi_1(a, b) \phi_2(b, c) \phi_3(c, d) \phi_4(d)$$

$$= \phi_1(a, b) \phi_2(b, c) \underbrace{\sum_d p(a|b) \phi_3(c, d) \phi_4(d)}_{\mu_{d \rightarrow c}(c)}$$

其中 $\mu_{d \rightarrow c}(c)$ 表示从 d 到 c 传递的信息.

Junction Tree算法 | 变量消除等方法解决单链接图的推断问题，如果概率图模型属于多连接图，推断需使用Junction Tree算法：

- ✓ 对原始的图进行**moralisation**，融合父节点.
- ✓ 对图进行**triangulation**构造**chordal graph**.
- ✓ 寻找graph中的极大团，构造Junction Tree.
- ✓ 在树结构上运行广义的sum-product算法.